

Alumno: Higuera Pineda Angel Abraham

Actividad: Analizar la formulación de un problema de Machine Learning

Contexto:

“Queremos usar un modelo para aprobar créditos automáticamente y reducir **tiempos de respuesta** que mejoren la experiencia del cliente. Sin embargo, también buscamos minimizar el riesgo de incumplimiento y mantener la rentabilidad del portafolio. Idealmente, el sistema debería **aprobar más solicitudes** que el esquema actual, pero sin **incrementar significativamente la tasa de morosidad**.”

1-. Analizar e identificar ambigüedades y conflictos

Ambigüedades: El contexto del problema carece de valores numéricos o métricas exactas

- Tiempo de respuesta: No especifica el tiempo actual a reducir
- Incrementar tasa de morosidad: Cuanto se debe incrementar, no cuenta con un valor actual, etc.
- Aprobar más solicitudes: No nos indica la tasa de solicitudes actual

Conflictos:

- Al aprobar más solicitudes se aumenta el riesgo de incumplimiento.
- Se desea reducir el tiempo de respuesta, se puede reducir eliminando variables de entrada, pero eso significa que el modelo no tendrá la alimentación adecuada para tener un buen análisis y reducir el riesgo.

2-. Identificar elementos que no estén completamente definidos y cuáles son los datos que deberíamos usar como entrada y salida.

Datos no definidos:	Datos de entrada	Datos de salida
Tasa de morosidad	Ingresos mensuales	Probabilidad que el usuario pague
Solicitudes que el esquema actual procesa	comprobables	Aprobado/no aprobado
Riesgo de incumplimiento actual	Historial crediticio	
Tiempo de respuesta actual/anterior	Monto del crédito solicitado	
Rentabilidad del portafolio	Plazo	

3-. Identifica supuestos implícitos y fuentes de posibles sesgos.

Sesgos:

- No toma en cuenta créditos rechazados al ser entrenado (Puede dejar de lado buenos clientes)
- Aprende de decisiones tomadas por personas en el pasado (Que aprobaban o rechazaban el crédito)

Supuestos:

- El comportamiento puede no cambiar al seguir el comportamiento pasado.
- Tomará como verdadero los datos ingresado (El usuario puede agregar datos falsos).
- Falta de datos como: Ingresos informales, gastos no registrados, apoyo familiar, etc.

4-. Describe el impacto potencial de los posibles sesgos y errores de definición.

Impacto financiero (falso negativo): Predice que alguien pagará pero termina no haciéndolo.

Impacto comercial (falso positivo): Predice que alguien no pagará siendo un buen cliente.

Impacto social: El banco podría tener problemas legales por discriminación algorítmica y daño reputacional.

5-. Propón las métricas más adecuadas para evaluar el modelo.

- Recall: Mide la capacidad del modelo para identificar a los verdaderos morosos. Es decir, de todos los clientes que *en la realidad* van a incumplir su pago, ¿qué porcentaje logró detectar y bloquear el modelo? Maximizar esta métrica es crucial para cumplir el objetivo de "minimizar el riesgo de incumplimiento"
- Precisión: Evalúa qué tan "seguro" está el modelo cuando emite un rechazo. De todas las solicitudes que el modelo etiquetó como "riesgosas", ¿cuántas realmente iban a caer en morosidad? Una alta precisión es vital para evitar rechazar por error a buenos clientes (Falsos Positivos), apoyando directamente el objetivo de "aprobar más solicitudes"